Extração de dados - mongoBD via python



Pacotes necessário do python

Para instalar os pacotes(bibliotecas) no python, basta usar o comando !pip3 install nome_pacote ou !pip3 install requirements.txt em que requirements.txt é um o arquivo texto com os nomes dos pacotes a serem instalados.

```
#!pip3 install -r requirements.txt # Basta rodar uma vez apenas

import numpy as np #tarefas matemáticas e machine learning
import pandas as pd #manipulação de data frames e machine learning
from pandas import Series, DataFrame
from datetime import datetime #manipulação de variáveis em formato de data
from pymongo import DESCENDING #util para acessar o mongoDB
from collections import OrderedDict
pd.set_option('display.max_columns', None) # Não limita o número de columas para visualização
```

Abaixo um exemplo de como acessar o mongoDB

```
from pymongo import MongoClient
def db_connect(ambient):
    if ambient == "prod":
        db_uri = "mongodb://credenciais_de_acesso_ao_mongoDB"
        db_name = "nome_da_base_de_dados"
   client = MongoClient(db_uri)
   db = client[db name]
    if not db:
        print("ERROR: Couldn't connect to database")
        return None
   return db
db = db_connect("prod")
# Define o período da coleta dos dados
period_start = datetime(2020, 8, 1, 0, 0, 0)
period_end =
               datetime(2020, 8, 2, 0, 0, 0)
entity_id = 12
```

Documentos na base de dados

```
# Distinct nos 'document_types' do banco
document_types = db.history_people.distinct('document_type', {'entidade_id': entity_id})
```

document_types

```
['medical_record',
  'vital_signs',
  'exams',
  'medicines',
  'pharmacy',
  'movements',
  'alert']
```

Consulta para extrair as informações de sinais vitais

```
query = {
   'entidade_id': entity_id,
   'document_type': 'vital_signs',
   'date': {'$gte': period_start,
            '$lte': period_end}
}
limiters = {
    '_id': 0,
    'date':1,
    'document.data_coleta':1,
    'document.data_liberacao':1,
    'document.freq_cardiaca':1,
    'document.freq_respiratoria':1,
    'document.glicemia_capilar':1,
    'document.nivel_consciencia':1,
    'document.pa_diastolica':1,
    'document.pa_sistolica':1,
    'document.sat_o2':1,
    'document.temperatura':1,
    'document.paciente_id':1
}
vs = list(db.history_people.find(query, limiters))
```

Tamano da amostra

```
len(vs)
```

7469

Formatando os dados para data frame

Dados de Sinais vitais

```
from pandas.io.json import json_normalize
```

```
### Transformando de formato JSON para data frame
df_vs = json_normalize(vs)
### Ordenando por data
df_vs.sort_values(by=['date'], inplace=True)
```

```
df_vs.head(5)
<ipython-input-22-51dfdbf79ed6>:2: FutureWarning: pandas.io.json.json_normalize is deprecated, use pand
  df_vs = json_normalize(vs)
date
document.data\_coleta
document.data\_liberacao
document.freq_cardiaca
document.freq\_respiratoria
document.glicemia\_capilar
document.nivel\_consciencia
document.pa\_diastolica
document.pa\_sistolica
document.paciente\_id
document.sat\_o2
document.temperatura
0
2020-08-01
2020-08-01
2020-08-01 00:03:45
131.0
22.0
NaN
None
62.0
135.0
731032
95.0
38.1
75
2020-08-01
2020-08-01
2020-08-01 03:02:58
86.0
16.0
```

NaN

 $\textit{### Visualizando as} \quad \textit{primiras linhas do data frame}$

None 54.0 93.02782882 100.0 35.9 74 2020-08-01 2020-08-01 $2020\hbox{-}08\hbox{-}01\ 03\hbox{:}02\hbox{:}05$ 117.0 16.0 87.0 None 66.0122.0 2802042100.0 36.273 2020 - 08 - 012020 - 08 - 012020-08-01 02:54:08 100.0 24.0 NaN None 62.0103.0 750156 97.0 38.272 2020-08-01 2020-08-01

 $2020\hbox{-}08\hbox{-}01\ 02\hbox{:}52\hbox{:}44$

82.0

28.0

NaN

None

67.0

128.0

1958456

92.0

36.7

len(df_vs)

7469

Nome das variáveis

```
df_vs.columns
```

Index(['entidade_id', 'atendimento_id', 'date', 'document.data_coleta', 'document.data_liberacao', 'document.freq_cardiaca', 'document.freq_respiratoria', 'document.glicemia_capilar', 'document.nivel_consciencia', 'document.pa_diastolica', 'document.pa_sistolica', 'document.paciente_id', 'document.sat_o2', 'document.temperatura'], dtype='object')

Exportando os dados localmente em formato csv

```
df_vs.to_csv('nome.csv', sep = ',', index = False)
```